

# Redes Neurais Artificiais: Artigo 2

Victor São Paulo Ruela  
Programa de Pós-Graduação em Engenharia Elétrica  
Universidade Federal de Minas Gerais  
Belo Horizonte, Brasil  
Email: victorspruela@ufmg.br

**Resumo**—Este trabalho tem como objetivo avaliar o desempenho de diferentes modelos de redes neurais artificiais estudados durante a disciplina sobre bases de dados de benchmark presentes na literatura. Serão considerados o Perceptron, Adaline, Redes RBF, ELM e ELM com aprendizado Hebbiano. Para três problemas de regressão e classificação binária escolhidos, um experimento foi desenhado seguindo as recomendações da literatura. Os resultados de cada modelos são comparados por meio de testes estatísticos para as métricas AUC (classificação) e coeficiente de correlação linear (regressão). Os resultados mostraram que ...

## I. INTRODUÇÃO

A Rede Neural Artificial (RNA) é uma classe de modelos muito popular em problemas de classificação, reconhecimento de padrões, regressão e predição [1]. Inspirado pelas características do cérebro humano, elas possuem como elementos básicos neurônios artificiais capazes de executar operações matemáticas, representando desta forma modelos de neurônios biológicos. Através de sua organização em diferentes estruturas de rede, tais modelos são capazes de se adaptar e representar funções matemáticas bastante complexas.

## II. METODOLOGIA

### A. Bases de Dados

1) *Classificação*: Serão consideradas as bases de dados. Suas informações estão resumidas na tabela:

2) *Regressão*:

### B. Desenho do experimento

A partir das recomendações para desenho de experimento para comparação de algoritmos proposta em [2], a seguinte metodologia será adotada:

1) Para cada base de dados:

- a) Particionar os dados  $D$  em  $k$  sub-grupos para validação cruzada, mantendo a mesma proporção entre os rótulos
  - i) Criar o conjunto de treino  $T = D - k$
  - ii) Dividir  $T$  em dois novos conjuntos  $T1$  e  $T2$ , mantendo a mesma proporção entre os rótulos
  - iii) Para cada valor de parâmetro de regularização  $\lambda$ :
    - A) Treinar cada modelo sobre  $T1$
    - B) Estimar a métrica de teste sobre  $T2$
- iv) Escolher  $\lambda$  que corresponde ao mínimo da curva de validação sobre  $T2$

- v) Avaliar a métrica do modelo sobre  $k$
- b) Estimar o intervalo de confiança do valor médio da métrica usando *bootstrapping*

## III. CONCLUSÕES

Neste trabalho foi feita uma revisão bibliográfica de alguns dos principais trabalhos sobre redes neurais artificiais. Realizando a divisão entre modelos para aprendizado supervisionado e não-supervisionado, os conceitos básicos dos modelos estudados foram apresentados para contextualização, bem como uma breve análise das principais evoluções e aplicações propostas na literatura. Cada um destes modelos possui uma enorme quantidade de trabalhos publicados, portanto é de se esperar que publicações importantes tenham sido omitidos.

Um aspecto não muito abordado neste trabalho foram as aplicações de RNAs, dado que o foco deste trabalho foi em entender um pouco mais de sua teoria. Em [3] está disponível uma lista das diferentes áreas em que RNAs são comumente aplicadas. Conforme observado durante a realização deste trabalho, grande partes das evoluções visam aprimorar eficiência dos algoritmos treinamento. Isso também é observado por [3], o qual considera uma tendência trabalhos futuros visando aprimorar este aspecto.

## REFERÊNCIAS

- [1] Anil K Jain, Jianchang Mao, and K Moidin Mohiuddin. Artificial neural networks: A tutorial. *Computer*, 29(3):31–44, 1996.
- [2] Steven L Salzberg. On comparing classifiers: Pitfalls to avoid and a recommended approach. *Data mining and knowledge discovery*, 1(3):317–328, 1997.
- [3] Oludare Isaac Abiodun, Aman Jantan, Abiodun Esther Omolara, Kemi Victoria Dada, Nachaat AbdElatif Mohamed, and Humaira Arshad. State-of-the-art in artificial neural network applications: A survey. *HeLyon*, 4(11):e00938, 2018.