

Maximização de Margem

Victor Ruela

Programa de Pós-Graduação em Engenharia Elétrica
Universidade Federal de Minas Gerais

victorspruela@ufmg.br

1 de fevereiro de 2021

Agenda

- 1 Introdução
 - Aprendizado Supervisionado
 - Minimização do Erro
- 2 Maximização de Margem
 - Padrões Não-linearmente Separáveis
 - Otimização
- 3 Exemplos
 - SVM

Problema de Classificação


- Dados de treinamento: $\mathcal{T} = \{(\mathbf{x}_1, d_1), \dots, (\mathbf{x}_N, d_N)\}$
- Para um problema de classificação binário: $d_i = \{-1, 1\}$
- Assume-se que os padrões são linearmente separáveis
- Em geral, algoritmos para treinamento de RNAs objetivam minimizar o erro quadrático:

$$\min \sum_{i=1}^N [d_i - \text{sign}(\mathbf{w}^T \mathbf{x}_i + b)]^2 \quad (1)$$

Minimização do Erro


- O resultado da solução do Problema 1 será um conjunto de pesos representando um hiperplano que separa estes padrões:

$$\mathbf{w}^T \mathbf{x} + b = 0 \quad (2)$$



O Hiperplano Ótimo

- Margem de separação: ρ
- Quando a escolha de \mathbf{w} e b maximizam ρ , o hiperplano é dito **ótimo** [Haykin, 2007].




O Hiperplano Ótimo

- A função discriminante ótima é definida como:

$$g(\mathbf{x}) = \mathbf{w}_o^T \mathbf{x} + b_o \quad (3)$$

- E distância deste hiperplano por:

$$r = \frac{g(\mathbf{x})}{\|\mathbf{w}_o\|} \quad (4)$$



O Hiperplano Ótimo

- Para otimalidade, o par (\mathbf{w}_o, b_o) deve satisfazer:

$$\begin{cases} \mathbf{w}_o^T \mathbf{x}_i \geq -1, d_i = +1 \\ \mathbf{w}_o^T \mathbf{x}_i \leq -1, d_i = -1 \end{cases} \quad (5)$$

- Os pontos (\mathbf{x}_i, d_i) que satisfazem com igualdade estas restrições são chamados de **vetores de suporte**
- Eles são os pontos mais próximos do hiperplano e consequentemente mais difíceis de classificar [Haykin, 2007].

O Hiperplano Ótimo

- Por definição:

$$g(\mathbf{x}^{(s)}) = \mathbf{w}_o^T \mathbf{x}^{(s)} + b_o = \mp 1 \quad (6)$$

- Logo, a distância do vetor de suporte $\mathbf{x}^{(s)}$ é dada por:

$$\begin{cases} \frac{1}{\|\mathbf{w}_o\|} & \text{se } d^{(s)} = +1 \\ \frac{-1}{\|\mathbf{w}_o\|} & \text{se } d^{(s)} = -1 \end{cases} \quad (7)$$

- Finalmente, a margem ótima ρ é:

$$\rho = \frac{2}{\|\mathbf{w}_o\|} \quad (8)$$

Conclusão

Maximizar a separação entre classes binárias é equivalente a minimizar a norma Euclidiana do vetor de pesos \mathbf{w}

Referências



Haykin, S. (2007). Neural Networks: A Comprehensive Foundation (3rd Edition).

Obrigado!