

# Fundamentos de Redes Neurais Artificiais

Victor São Paulo Ruela  
Programa de Pós-Graduação em Engenharia Elétrica  
Universidade Federal de Minas Gerais  
Belo Horizonte, Brasil  
Email: victorspruela@ufmg.br

**Resumo**—Este trabalho tem como objetivo apresentar uma revisão da literatura de redes neurais artificiais, com enfoque na evoluções das principais técnicas clássicas.

## I. INTRODUÇÃO

A Redes Neural Artificial (RNA) é uma classe de modelos muito popular em problemas de classificação, reconhecimento de padrões, regressão e predição [1]. Inspirado pelas características do cérebro humano, elas possuem como elementos básicos neurônios artificiais capazes de executar operações matemáticas, representando desta forma modelos de neurônios biológicos. Através de sua organização em diferentes estruturas de rede, tais modelos são capazes de se adaptar e representar funções matemáticas bastante complexas.

Diferentes representações estão presentes na literatura, as quais são classificadas de acordo com o seu nível de complexidade e requisitos computacionais de implementação. Hipóteses básicas para regras de aprendizado de associações entre neurônios podem ser encontradas em trabalhos bastante antigos, como abordado no livro de William James em 1982 [2]. Entretanto, um grande marco desta área de pesquisa ocorreu na década de 40 após a introdução do modelo de McCulloch and Pitts (MCP) [3], o qual é adotado atualmente nos principais modelos de RNAs.

O modelo MCP tem como saída a soma das ativações dos neurônios anteriores ponderados pelos pesos das conexões entre eles. Uma função de ativação do tipo degrau é aplicada sobre esta saída, configurando modelo de soma-e-limiar originalmente descrito pelos autores. Este trabalho apresentou a configuração de diversas redes de neurônios MCP, com enfoque na implementação de funções lógicas. Vale a pena notar que os primeiros computadores digitais estavam surgindo nesta época, motivando esta aplicação. Entretanto, as estruturas apresentadas eram estáticas e não houve a sugestão de algum método de aprendizado para adaptá-las,

O aprendizado surgiu de forma mais concreta com o postulado de Hebb [4], originalmente publicado em 1949. De acordo com o autor, a eficiência de uma determinada sinapse que conecta dois neurônios é proporcional à co-ocorrência de ativação entre eles. Portanto, o princípio de aprendizado Hebbiano visa reforçar as conexões relevantes para as diferentes saídas da rede, guiado pela correlação entre os neurônios.

A partir destes princípios elementares, a área de RNAs evoluiu bastante nas últimas décadas. Após a introdução das primeiras regras de aprendizado, este tipo de modelo ganhou

maior visibilidade e aplicabilidade para problemas reais, sendo possível encontrar uma enorme quantidade de aplicações publicadas [5]. Além disso, o aumento dos recursos computacionais disponíveis fomentou o desenvolvimento de novas técnicas para aprendizado e o aprimoramento das existentes, além de propostas de novas estruturas redes complexas capazes de lidar com problemas de grande dificuldade.

Portanto, o objetivo deste trabalho é apresentar a uma revisão da literatura contendo os principais trabalhos que levaram à evolução dos diferentes modelos de redes neurais presentes no dia de hoje. Partindo das referências clássicas, diferentes abordagens propostas serão analisadas de forma cronológica como forma de se entender a evolução desta área de pesquisa até o tempo presente.

## II. APRENDIZADO SUPERVISIONADO

RNAs de aprendizado supervisionado são responsáveis pela inferência de uma função desconhecida  $f(\cdot)$  que realiza o mapeamento entre uma saída e um conjunto de entradas medidas, representada pelo conjunto de  $N$  pares de dados  $\mathcal{D} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$ . Problemas de classificação e regressão são comumente solucionados com estas técnicas, para os quais as primeiras estruturas de rede e algoritmos de treinamento descritos na literatura são o *Adaline*, em 1960, e o *Perceptron* simples, em 1957.

### A. Adaline

### B. Perceptron

Proposto inicialmente por Rosenblatt [6], este é um modelo geralmente utilizado para a solução de problemas de classificação. No seu trabalho original, o autor descreve formas de adaptação dos parâmetros, ou pesos, da rede com o objetivo de reduzir a discrepância entre as saídas esperadas e estimadas e aprender associações entre os neurônios, o que é a base da indução para diversos algoritmos atuais. Este trabalho é considerado um marco na literatura por diversos autores.

Embora descrito como uma rede de duas camadas, originalmente seu treinamento só considerava uma camada. Por esse motivo, o Perceptron simples é comumente descrito na forma de somente um neurônio MCP. Sua regra de aprendizado é bem direta e consiste em alterar iterativamente os pesos da rede de acordo com a seguinte regra:

$$\mathbf{w}(k+1) = \mathbf{w}(k) + \eta e(k) \mathbf{x}(k) \quad (1)$$

onde  $\mathbf{x}(k)$ ,  $e(k)$  e  $\mathbf{x}(k)$  são o vetor de pesos, o erro e o vetor de entradas na  $k$ -ésima iteração do treinamento, respectivamente. A constante  $\eta$  é um escalar utilizado para controlar o tamanho do passo em cada iteração.

Se considerarmos uma função de ativação contínua e diferenciável, os pesos da rede poderão ser inferidos de forma explícita, através do cálculo da pseudo-inversa, ou pelo algoritmo do gradiente descendente [7], similar à regra delta introduzida pelo Adaline. Exemplos de funções de ativação com esta característica frequentemente empregadas na literatura são a sigmoide, tangente hiperbólica e linear. Vale a pena ressaltar que a convergência destas abordagens está condicionada aos dados utilizados para treinamento serem linearmente independentes [7].

Rosenblatt provou a convergência da regra de aprendizado original, porém a mesma só é garantida para problemas linearmente separáveis [8], o que constitui a principal limitação deste modelo. Após este trabalho, Rosenblatt avaliou diferentes arquiteturas de rede tentando superar esta limitação, porém não chegou ao desenvolvimento de uma regra para aprendizado dos pesos. Por conta disso, o Perceptron foi pouco estudado pelos próximos de 20 anos [7].

O interesse pelo Perceptron retornou na década de 80 com a descrição do método de aprendizado conhecido como *back-propagation*, o qual é capaz de aprender os pesos de redes de múltiplas de forma eficiente [9]. Aliado a isso, o Perceptron de múltiplas camadas é capaz de descrever superfícies de separação não-lineares, superando a principal limitação do trabalho de Rosenblatt. Uma descrição mais completa desta técnica é feita na próxima seção.

C. *Perceptron de múltiplas camadas*

D. *Máquinas de aprendizado extremo*

E. *Redes RBF*

F. *Máquinas de vetores suporte*

G. *Aprendizado multiobjetivo*

### III. APRENDIZADO NÃO-SUPERVISIONADO

A. *Aprendizado Hebbiano*

B. *SOM*

C. *Máquinas de Vetores Suporte*

D. *Aprendizado Multiobjetivo*

### REFERÊNCIAS

- [1] Anil K Jain, Jianchang Mao, and K Moidin Mohiuddin. Artificial neural networks: A tutorial. *Computer*, 29(3):31–44, 1996.
- [2] William James. *Psychology, briefer course*, volume 14. Harvard University Press, 1984.
- [3] Warren S McCulloch and Walter Pitts. A logical calculus of the ideas immanent in nervous activity. *The bulletin of mathematical biophysics*, 5(4):115–133, 1943.
- [4] Donald Olding Hebb. *The organization of behavior: A neuropsychological theory*. Psychology Press, 2005.
- [5] Oludare Isaac Abiodun, Aman Jantan, Abiodun Esther Omolara, Kemi Victoria Dada, Nachaat Abdelatif Mohamed, and Humaira Arshad. State-of-the-art in artificial neural network applications: A survey. *Heliyon*, 4(11):e00938, 2018.
- [6] Frank Rosenblatt. *The perceptron, a perceiving and recognizing automaton Project Para*. Cornell Aeronautical Laboratory, 1957.

- [7] John Hertz, Anders Krogh, Richard G Palmer, and Heinz Horner. Introduction to the theory of neural computation. *PhT*, 44(12):70, 1991.
- [8] Marvin Minsky and Seymour Papert. An introduction to computational geometry. *Cambridge tiass.*, HIT, 1969.
- [9] David E Rumelhart, Geoffrey E Hinton, and Ronald J Williams. Learning internal representations by error propagation. Technical report, California Univ San Diego La Jolla Inst for Cognitive Science, 1985.